

Curadoria Discente de Artigos Científicos como Proxy de Aprendizado: Um Estudo Observacional Baseado em Alinhamento Semântico à Ementa e em um Índice de Qualidade Pedagógica

Grupo 2

Medição e Experimentação em Engenharia de Software – PUC Minas

Resumo—Este artigo apresenta um estudo observacional sobre 73 artigos científicos apresentados por alunos em três turmas da disciplina de Medição e Experimentação em Engenharia de Software da PUC Minas. O aprendizado, não mensurável diretamente, é operacionalizado em duas camadas complementares: um proxy inferencial — o alinhamento semântico entre cada artigo e a ementa, via similaridade de cosseno entre embeddings — e um índice de qualidade pedagógica (IQAP) que combina seis dimensões avaliadas a partir do texto e dos metadados de cada artigo. A abordagem Goal-Question-Metric (GQM) [1] estrutura as questões de pesquisa, respondidas por um pipeline reproduzível com enriquecimento bibliográfico (OpenAlex), rede de acoplamento bibliográfico, dois índices compostos — o pedagógico (IQAP) e o bibliométrico (ARQI) — e testes não paramétricos. O corpus alinha-se à ementa muito acima de uma seleção aleatória da área (Mann-Whitney $U = 12107$, $p < 0,001$, δ de Cliff = $+0,922$); a diferença entre turmas concentra-se em um único par ($p = 0,005$, $\delta = +0,599$); a composição de tipos de veículo é estável ($\chi^2 = 4,10$, $p = 0,663$); o IQAP médio é 0,487 (14 artigos bons, 28 regulares, 24 fracos), com a qualidade metodológica (0,378) como principal ponto de atenção; e o ranking ARQI é robusto à escolha de pesos ($\rho \geq 0,917$). Uma classificação qualitativa automática (tipo metodológico e grau de relação à ementa) responde a três das seis questões qualitativas do enunciado. O pipeline é a ferramenta ACARI, validada por teste cruzado com ementa de outra área (queda de 49% no alinhamento).

I. INTRODUÇÃO

A discussão de artigos científicos em sala de aula é um método didático consolidado em Engenharia de Software Empírica. Em três turmas da disciplina de Medição e Experimentação em Engenharia de Software da PUC Minas (Coração Eucarístico 2025/2, Lourdes 2025/2 e Lourdes 2026/1), cada aluno selecionou e apresentou um artigo relacionado aos temas do curso, formando um corpus de 73 trabalhos. O problema de pesquisa é a ausência de evidência objetiva sobre essa curadoria: não se sabe, de forma mensurável, se os artigos escolhidos refletem o conteúdo do plano de ensino ou se equivalem a uma amostra aleatória da área, o que dificulta avaliar o papel pedagógico da atividade. Avaliar manualmente relevância, tipo, replicabilidade e nível de cada artigo, como pede o enunciado, é caro e subjetivo; este trabalho propõe medir essas dimensões automaticamente, no nível do corpus.

Como o aprendizado individual não foi medido diretamente, o estudo adota uma medição indireta em duas camadas. A primeira é um proxy inferencial: o construto “potencial de aprendizado” é operacionalizado pelo alinhamento semântico de cada artigo com a ementa, testado contra uma linha de base aleatória. A segunda é uma medida pedagógica descritiva: o *Índice de Qualidade Acadêmica e Pedagógica* (IQAP), que pondera adequação à ementa, qualidade metodológica, replicabilidade, aplicabilidade, acessibilidade e qualidade bibliográfica. Enquanto o alinhamento responde “o corpus está acima do acaso?”, o IQAP responde “quão bons para aprender esta disciplina são os artigos?”. Trata-se de um estudo de natureza aplicada, abordagem quantitativa, recorte transversal e controle não experimental (observacional) [2].

As hipóteses que orientam o estudo são organizadas em duas camadas. A camada conceitual, derivada do enunciado, postula que a leitura dos artigos impacta o aprendizado previsto no plano de ensino. Como não há *survey* de aprendizado, ela é operacionalizada pela camada de proxy e complementada pela evidência pedagógica do IQAP:

- **H1 (conceitual):** a leitura do corpus curado impacta, na média, o aprendizado previsto na ementa — operacionalizada por **H1_{op}**: o alinhamento médio do corpus à ementa é superior ao de uma seleção aleatória de artigos de Engenharia de Software, com o IQAP caracterizando a qualidade pedagógica do conjunto;
- **H2 (entre turmas):** o alinhamento à ementa difere entre as três turmas;
- **H3 (deriva de veículo):** a proporção de tipos de veículo de publicação difere entre as turmas;
- **H4 (estabilidade do índice):** o índice bibliométrico ARQI produz ranking estável sob diferentes esquemas de pesos.

II. DEFINIÇÃO DO GQM

A. Objetivo Geral

O objetivo geral deste estudo, no template de Basili et al. [1], é definido como segue. **Propósito:** analisar o corpus de artigos apresentados em sala, a fim de caracterizar e avaliar o grau de alinhamento da curadoria discente com o conteúdo previsto no plano de ensino. **Perspectiva:** examinar a relevância temática,

a qualidade pedagógica, a qualidade bibliométrica e a evolução entre turmas, do ponto de vista do aprendizado previsto no plano de ensino e do pesquisador em Engenharia de Software Empírica. **Ambiente:** 73 artigos apresentados em três turmas da disciplina (2025/2 e 2026/1), enriquecidos via APIs OpenAlex e Crossref, processados por pipeline Python automatizado com embeddings de linguagem natural (all-MiniLM-L6-v2), análise de redes e testes estatísticos não paramétricos, tendo como referência textual a ementa, as unidades de ensino, os objetivos e a bibliografia básica do plano de ensino oficial. O objetivo conecta-se às Unidades 1 a 3 da ementa: métricas de produto e processo, testes de hipótese e análise multivariada, e condução de estudos empíricos.

B. Objetivos Específicos

- **Obj1:** caracterizar o corpus quanto a temas, anos, veículos, citações e tipos de publicação, a fim de compreender o perfil bibliométrico da curadoria discente;
- **Obj2:** avaliar o alinhamento semântico do corpus à ementa frente a uma linha de base aleatória, a fim de verificar se a curadoria supera o acaso;
- **Obj3:** comparar o alinhamento à ementa entre as três turmas, a fim de identificar deriva temática ao longo do tempo;
- **Obj4:** avaliar a composição de tipos de veículo entre as turmas, a fim de verificar a estabilidade do padrão de escolha de fontes;
- **Obj5:** propor um indicador bibliométrico composto de relevância e qualidade (ARQI), a fim de ranquear os artigos e avaliar a robustez do ranking à escolha de pesos;
- **Obj6:** propor um índice de qualidade pedagógica (IQAP), a fim de caracterizar quão adequado à aprendizagem da disciplina é o corpus, para além da força bibliométrica;
- **Obj7:** classificar automaticamente os artigos quanto ao tipo metodológico e ao grau de relação com a ementa, a fim de responder de forma reprodutível a parte das questões qualitativas do enunciado.

C. Questões de Pesquisa

- **RQ01 (Obj1):** quais são as características bibliométricas do corpus apresentado pelas três turmas?
- **RQ02 (Obj2):** o alinhamento médio do corpus à ementa é superior ao de uma seleção aleatória de artigos de Engenharia de Software?
- **RQ03 (Obj3):** o alinhamento à ementa difere entre as três turmas?
- **RQ04 (Obj4):** a proporção de tipos de veículo difere entre as turmas?
- **RQ05 (Obj5):** o ranking produzido pelo ARQI é estável sob diferentes esquemas de pesos?
- **RQ06 (Obj6):** qual é o potencial pedagógico do corpus segundo o IQAP, e qual dimensão limita esse potencial?
- **RQ07 (Obj7):** tipo metodológico e grau de relação com a disciplina podem ser classificados automaticamente a partir do texto?

D. Tabela de Métricas

A Tabela I relaciona as métricas do estudo, o tipo de atributo e a escala de medição. O `alignment_score` é a variável dependente inferencial (usada em RQ02 e RQ03); o IQAP é a variável dependente pedagógica (RQ06); ambos são medições derivadas. As variáveis independentes (fatores de comparação) são `cohort`, `year` e `venue_type`; popularidade do tema e esforço do apresentador são fatores de confusão, tratados como ameaças à validade.

Tabela I
MÉTRICAS DO ESTUDO, ATRIBUTOS E ESCALAS.

Métrica	Atributo	Escala	RQ
<code>alignment_score</code>	Dep. inferencial (deriv.)	Razão [0, 1]	RQ02, RQ03
<code>IQAP</code>	Dep. pedagógica (deriv.)	Razão [0, 1]	RQ06
<code>citations</code>	Externo	Razão	RQ01, RQ05
<code>year / recency_score</code>	Interno	Razão	RQ01, RQ05
<code>n_references</code>	Interno	Razão	RQ01
<code>prestige_score</code>	Externo	Razão [0, 1]	RQ05
<code>pagerank centrality</code>	Externo	Razão [0, 1]	RQ05
<code>venue_type</code>	Interno	Nominal	RQ01, RQ04
<code>cohort (turma)</code>	Contexto	Nominal	RQ03, RQ04
<code>tipo_metodologico</code>	Interno	Nominal	RQ07
<code>relacao_disciplina</code>	Externo (derivada)	Ordinal	RQ07
<code>ARQI</code>	Externo (derivada)	Razão [0, 1]	RQ05

E. Árvore do GQM

- **Goal:** avaliar o alinhamento e a qualidade pedagógica da curadoria discente ao plano de ensino
 - **Obj1** → RQ01 → `citations`, `year`, `venue_type`, `n_references`
 - **Obj2** → RQ02 → `alignment_score` (corpus vs. base-line)
 - **Obj3** → RQ03 → `alignment_score` por turma
 - **Obj4** → RQ04 → `venue_type` por turma
 - **Obj5** → RQ05 → ARQI (`alignment`, `prestige`, `citations`, `recency`, `centrality`)
 - **Obj6** → RQ06 → IQAP (`Ped`, `Met`, `Rep`, `Apl`, `Acess`, `Bib`)
 - **Obj7** → RQ07 → `tipo_metodologico`, `relacao_disciplina`

F. Tabela Consolidada do GQM

Tabela II
VISÃO CONSOLIDADA DO GQM COM OS TESTES APLICADOS.

Objetivo	RQ	Métricas	Análise
Obj1	RQ01	bibliométricas	estatística descritiva
Obj2	RQ02	<code>alignment_score</code>	Mann-Whitney U, δ , permutação
Obj3	RQ03	<code>alignment_score</code>	Kruskal-Wallis, Dunn (BH), δ
Obj4	RQ04	<code>venue_type</code>	Qui-quadrado, V de Cramér
Obj5	RQ05	ARQI	PCA, Spearman entre rankings
Obj6	RQ06	IQAP (6 dim.)	média ponderada, descritiva por dimensão
Obj7	RQ07	tipo, relação	regras de texto + tercís

III. METODOLOGIA

A Figura 1 resume o pipeline de medição: dez etapas automatizadas que partem do manifesto do corpus e do plano de ensino e produzem as figuras, tabelas e testes deste artigo.




Figura 1. Pipeline de medição (ferramenta ACARI): entradas, dez etapas automatizadas e saídas.

A. Corpus e Enriquecimento

O corpus foi catalogado manualmente a partir das apresentações das três turmas, totalizando 73 itens. Cada item foi enriquecido por um pipeline automatizado: o casamento bibliográfico utilizou a API OpenAlex [5] com prioridade para DOI e, na ausência deste, busca difusa de título (`token_set_ratio` ≥ 72) validada por diferença máxima de 8 anos entre o ano declarado e o retornado, com fallback para a API Crossref. A cobertura final foi de 71 dos 73 itens (97%). Itens que não são artigos de periódico ou conferência (livros, relatórios técnicos, revistas de divulgação e uma monografia, totalizando 10 itens) foram mantidos na caracterização, porém excluídos dos testes estatísticos, restando 63 artigos com `alignment_score` válido para inferência.

B. Alinhamento Semântico (Proxy)

O texto de referência da disciplina (ementa, unidades de ensino, objetivos e bibliografia básica do plano de ensino) foi segmentado em 7 trechos de aproximadamente 200 palavras; cada trecho foi convertido em vetor de 384 dimensões pelo modelo `all-MiniLM-L6-v2` [4], e o vetor da disciplina é a média dos segmentos. Para cada artigo utilizou-se o `abstract` retornado pelo OpenAlex (`abstract_inverted_index`) ou, na sua ausência, o texto da primeira página do PDF. O `alignment_score` é a similaridade de cosseno entre os dois vetores, no intervalo $[0, 1]$. O embedding semântico captura significado, e não apenas termos em comum, ao contrário da busca por palavra-chave.

C. Linha de Base Aleatória

Para testar RQ02 construiu-se uma linha de base com 200 artigos aleatórios do conceito *Software Engineering* do OpenAlex (C41008148, filtro `has_abstract:true`), com semente fixa para reprodutibilidade, e calculou-se o mesmo `alignment_score` para cada um.

D. Rede de Acoplamento Bibliográfico

Dois artigos foram conectados quando compartilham ao menos uma referência (acoplamento bibliográfico), com peso

igual ao tamanho da interseção dos conjuntos de referências obtidos do OpenAlex. Sobre o grafo resultante calculou-se a centralidade PageRank (normalizada pelo máximo) e detectaram-se comunidades pelo algoritmo de Louvain, que servem de base para a análise de distribuição temática por turma.

E. Índice Pedagógico IQAP

O *Índice de Qualidade Acadêmica e Pedagógica* (IQAP) mede se um artigo é bom para a disciplina, e não apenas se é bibliometricamente forte. Ele combina seis dimensões normalizadas em $[0, 1]$ pela média ponderada:

$$\text{IQAP}_i = 0,25 \text{Ped}_i + 0,20 \text{Met}_i + 0,20 \text{Rep}_i + 0,15 \text{Apl}_i + 0,10 \text{Acess}_i + 0,10 \text{Bib}_i, \quad (1)$$

em que **Ped** é a adequação pedagógica aos tópicos da ementa e a sobreposição temática (derivada da ementa e do texto do artigo); **Met** é a qualidade metodológica (presença de método, resultados, métricas, estatística e amostra, extraídos do PDF); **Rep** é a replicabilidade (método descrito, dados/código, referências e ameaças); **Apl** é a aplicabilidade prática (estudos empíricos, ferramentas, frameworks e casos reais, a partir da classificação do artigo); **Acess** é a acessibilidade (tamanho, idioma, resumo e complexidade estatística); e **Bib** é a qualidade bibliográfica (referências, DOI, ano e tipo de veículo). As dimensões são calculadas a partir de colunas do arquivo `metricas_bons_artigos.csv` (entre elas `pedagogical_fit_score`, `method_quality_score` e `replicability_score`). O IQAP é complementar ao ARQI: enquanto o ARQI responde “quais artigos são fortes academicamente?”, o IQAP responde “quais artigos são bons para aprender esta disciplina?”.

F. Índice Bibliométrico ARQI

O *Article Relevance and Quality Index* (ARQI) ordena a relevância acadêmica dos artigos e não substitui o IQAP. Combina cinco dimensões normalizadas para $[0, 1]$: alinhamento à ementa, prestígio do veículo (percentil de h-index e citação

média de 2 anos da fonte OpenAlex), impacto (rank percentil de $\log(\text{citações} + 1)$), recência (min-max do ano) e centralidade (PageRank). Valores ausentes não são imputados como zero: o índice é a média ponderada das dimensões disponíveis. Três configurações de pesos foram comparadas: pesos derivados do primeiro componente principal (PCA, que explica 41,9% da variância), pesos iguais e pesos iguais excluindo o prestígio (dimensão com 26 valores ausentes).

G. Classificação Qualitativa Automática

Para responder de forma reproduzível a parte das questões qualitativas do enunciado, duas classificações são derivadas automaticamente. O grau de relação com a ementa é obtido por tercís do `alignment_score` (itens com `in_stat_test`), com cortes em 0,363 e 0,460, gerando as faixas fraca, indireta e direta. O tipo metodológico (empírico, revisão ou teórico) é inferido por regras determinísticas de palavra-chave sobre título e *abstract*, com prioridade revisão > empírico > teórico e registro de confiança quando nenhuma palavra-chave é encontrada. Conforme detalhado na Seção IV-H, as seis questões qualitativas do enunciado são respondidas em dois níveis: *por artigo* quando derivável do texto, e *no nível do projeto* quando dependem da percepção individual do leitor.

H. Testes Estatísticos

Dado o tamanho amostral e a ausência de garantia de normalidade, adotaram-se testes não paramétricos: Mann-Whitney U unilateral para RQ02, Kruskal-Wallis com post-hoc de Dunn e correção de Benjamini-Hochberg para RQ03, e qui-quadrado com V de Cramér para RQ04. Tamanhos de efeito foram reportados pelo δ de Cliff, e a robustez do resultado principal foi verificada por teste de permutação com 10.000 reamostragens. O nível de significância adotado foi $\alpha = 0,05$.

I. Reprodutibilidade e Generalização

Todo o estudo é reproduzível com um único comando (`python run_pipeline.py`, aproximadamente 256 segundos), com dados congelados versionados. O pipeline é a ferramenta ACARI, parametrizada por arquivo de configuração (ementa em PDF ou texto, corpus em CSV, conceito da linha de base e coluna de grupos opcional), permitindo replicar o estudo em qualquer disciplina.

IV. RESULTADOS

A. RQ01: Caracterização do Corpus

O corpus contém 73 itens distribuídos em três turmas: Coração Eucarístico 2025/2 ($n = 11$), Lourdes 2025/2 ($n = 23$) e Lourdes 2026/1 ($n = 29$) entre os itens válidos para teste. Predominam artigos de periódico (48), seguidos de preprints (11) e artigos de conferência (4); os demais itens são relatórios, revistas de divulgação, livro e monografia. A Figura 2 apresenta a distribuição. A rede de acoplamento bibliográfico (Figura 3) possui 73 nós, 190 arestas e 26 componentes conexos, com 30 comunidades de Louvain, refletindo a diversidade temática do corpus.




Figura 2. Distribuição de tipos de veículo no corpus ($n = 73$); verde entra no teste, cinza apenas na caracterização.

A distribuição das comunidades de Louvain por turma (Figura 4) revela três padrões: *sobreposição* (mesmos artigos apresentados em turmas diferentes e clusters de métricas de produto/defeito comuns às três turmas), *continuidade* (um eixo estável de medição/métricas e experimentação ao longo das turmas) e *complementação* (a turma Lourdes 2026/1 acrescenta temas atuais — código gerado por IA, DORA/DAT/SPACE — que estendem, e não repetem, o núcleo anterior).




Figura 4. Comunidades de Louvain por turma; grupos pequenos agregados em “Outros”.

B. RQ02: Corpus versus Linha de Base

O alinhamento do corpus (média 0,426, mediana 0,447, desvio padrão 0,129, $n = 63$) superou amplamente o da linha de base aleatória (média 0,114, mediana 0,097, $n = 200$). O teste de Mann-Whitney rejeitou a hipótese nula com $U = 12107$ e $p < 0,001$ (unilateral), com δ de Cliff = +0,922, magnitude grande, confirmado por teste de permutação ($p < 0,001$). A Figura 5 ilustra a separação das distribuições.




Figura 5. Distribuição do alinhamento: corpus versus linha de base aleatória.




Figura 3. Rede de acoplamento bibliográfico: cor indica comunidade de Louvain, tamanho do nó é proporcional ao PageRank e os rótulos identificam os dez artigos mais centrais.

C. RQ03: Comparação entre Turmas




Figura 6. Alinhamento à ementa por turma, com par significativo destacado.

O teste de Kruskal-Wallis indicou diferença global significativa ($H = 10,643$, $p = 0,005$). No post-hoc de Dunn com correção de Benjamini-Hochberg, o único par significativo foi Coração Eucarístico 2025/2 versus Lourdes 2026/1 ($p = 0,005$, $\delta = +0,599$, magnitude grande); os pares restantes não atingiram significância ($p = 0,120$ e $p = 0,079$). A Figura 6 apresenta as distribuições por turma.

D. RQ04: Tipos de Veículo entre Turmas

O teste qui-quadrado não indicou diferença na composição de tipos de veículo entre as turmas ($\chi^2 = 4,10$, $gl = 6$, $p = 0,663$; V de Cramér = 0,179, efeito pequeno). A hipótese nula não foi rejeitada.

E. RQ05: Indicador Bibliométrico ARQI e Estabilidade

Os pesos derivados do PCA atribuíram maior carga à recência (0,591) e ao impacto por citações (0,514), seguidos de centralidade (0,435), alinhamento (0,410) e prestígio (0,172). O quadrante relevância $\times$ qualidade (Figura 7) posiciona cada artigo por alinhamento e prestígio, com tamanho proporcional ao ARQI e cor por turma. A análise de correlação de Spearman entre dimensões (Figura 8) evidencia uma tensão estrutural: artigos mais citados tendem a ser menos alinhados ($\log(\text{cit.}) \times \text{alinhamento} = -0,90$; PageRank $\times$ alinhamento = $-0,82$), e artigos antigos acumulam mais citações ($\text{recência} \times \log(\text{cit.}) = -0,64$). A Tabela III mostra a correlação de Spearman entre os rankings das três configurações de pesos: todos os pares apresentaram $\rho \geq 0,917$, indicando ranking altamente estável.




Figura 7. Quadrante relevância $\times$ qualidade: X = alinhamento; Y = prestígio (log-citações quando ausente); tamanho $\propto$ ARQI; cor por turma.




Figura 8. Correlações de Spearman entre dimensões do corpus ($|\rho| \geq 0,30$ anotadas).

Tabela III
ESTABILIDADE DO RANKING ARQI ENTRE CONFIGURAÇÕES DE PESOS.

Comparação	ρ de Spearman	p
PCA vs. Igual	0,960	$< 0,001$
PCA vs. Sem Prestígio	0,973	$< 0,001$
Igual vs. Sem Prestígio	0,917	$< 0,001$

F. RQ06: Índice Pedagógico IQAP

O IQAP foi calculado para os 73 artigos, com média 0,487 e mediana 0,484, distribuídos em 14 artigos bons, 28 regulares e 24 fracos — ou seja, 42 artigos com qualidade pedagógica ao menos regular. Entre as dimensões, a replicabilidade apresentou a maior média (0,543) e a adequação pedagógica resultou em 0,482, enquanto a qualidade metodológica foi a mais baixa (0,378), constituindo o principal ponto de atenção do corpus; apenas 1 artigo declarou dados ou código disponíveis. A Tabela IV lista os cinco artigos de maior IQAP. A leitura é direta: embora o corpus esteja bem alinhado à ementa (RQ02), nem todo artigo alinhado é automaticamente um bom artigo pedagógico, e a fragilidade metodológica média modera o potencial de aprendizado.

Tabela IV
TOP-5 ARTIGOS POR IQAP (DE METRICAS_BONS_ARTIGOS.CSV).

#	Artigo	IQAP	Classe
1	Experimentation in Software Engineering	0,738	bom
2	External Replication on Test-driven Dev.	0,732	bom
3	Empirical Validation of Cognitive Complexity	0,725	bom
4	What's DAT? Developer Productivity at Meta	0,705	bom
5	Metrics for Transparency in SE	0,703	bom

G. RQ07: Classificação Qualitativa Automática

A classificação por tercís distribuiu os artigos com alinhamento em 28 de relação direta, 22 indireta e 21 fraca. O tipo metodológico resultou em 43 artigos empíricos, 21 de revisão e 9 teóricos, com 64 dos 73 itens classificados por correspondência explícita de palavra-chave (confiança alta). Assim, três das seis questões qualitativas do enunciado (alinhamento ao plano, grau de relação e tipo metodológico) são respondidas automaticamente a partir dos dados, sem anotação manual.

H. As Seis Perguntas Qualitativas do Enunciado

As seis perguntas do enunciado são respondidas em dois níveis (Tabela V). As três deriváveis do texto — alinhamento ao plano, grau de relação e tipo metodológico — são respondidas *por artigo* pela ferramenta ACARI. As três restantes — replicabilidade percebida, nível do aluno e valor agregado — dependem da percepção individual do leitor e são respondidas *no nível do projeto*, atestadas pela própria experiência do grupo ao executar o estudo: o corpus é sobre medição, métricas e experimentação, exatamente os métodos aplicados neste trabalho; o estudo é reproduzível por um comando, logo é em si um artefato replicável; e a leitura do corpus gerou um produto concreto (a ferramenta ACARI e este estudo de

caso), demonstrando valor agregado cumulativo e não apenas declarado.

Tabela V
AS SEIS QUESTÕES QUALITATIVAS RESPONDIDAS EM DOIS NÍVEIS.

Pergunta	Nível	Resposta
Alinhado ao plano?	por artigo	Sim ($\delta = +0,922$ vs. baseline)
Relação direta/indireta?	por artigo	28 direta / 22 indireta / 21 fraca
Prático ou teórico?	por artigo	43 empírico / 21 revisão / 9 teórico
Replicável?	projeto	Sim (evidência do estudo)
No nível do aluno?	projeto	Sim (evidência do estudo)
Agregou valor?	projeto	Sim (evidência do estudo)

I. Validação Cruzada da Ferramenta

Como verificação adicional de construto, os mesmos artigos foram comparados, por meio da ferramenta ACARI, com uma ementa de outra área (Ciência de Dados): o alinhamento médio caiu de 0,556 para 0,286, uma redução de 49%, indicando que a métrica é sensível ao conteúdo da disciplina de referência e não um artefato do modelo de embedding.

V. DISCUSSÃO

RQ02 (H1): confirmada. O efeito ($\delta = +0,922$) indica que, sorteando um artigo do corpus e um da linha de base, o do corpus tem maior alinhamento em mais de 92% dos pares: a curadoria reflete a ementa muito acima do acaso, sustentando o proxy adotado. O IQAP complementa essa conclusão ao mostrar que 42 dos 73 artigos têm qualidade pedagógica ao menos regular, ainda que a média (0,487) seja moderada.

RQ03 (H2): parcialmente confirmada. A diferença global concentra-se em um único par após correção. A turma Lourdes 2026/1, a mais recente e a maior, apresentou o menor alinhamento mediano, com temas emergentes (código gerado por IA, métricas de produtividade como DORA e SPACE). Interpreta-se como deriva temática exploratória, condicionada ao tamanho amostral.

RQ04 (H3): contrariada. As três turmas escolhem proporções semelhantes de periódicos, conferências e preprints. O achado negativo é relevante: o padrão de fontes é estável mesmo diante da deriva temática de RQ03.

RQ05 (H4): confirmada. O ranking ARQI é robusto à escolha de pesos, inclusive à exclusão da dimensão mais incompleta (prestígio), afastando a interpretação de artefato de parametrização. As correlações negativas entre citações e alinhamento mostram que relevância bibliométrica e aderência à ementa são eixos distintos — justamente o que motiva um índice pedagógico separado.

RQ06 (IQAP): potencial pedagógico moderado. O corpus tem valor pedagógico (IQAP = 0,487; 14 bons, 28 regulares), mas a qualidade metodológica (0,378) e a quase ausência de dados/código abertos (1 artigo) são os limitadores. IQAP e ARQI são complementares: o ARQI ranqueia força bibliométrica, o IQAP ranqueia adequação à aprendizagem da disciplina.

RQ07: classificação viável. Tipo metodológico e grau de relação são deriváveis automaticamente do texto para a maioria dos itens (64 de 73 com alta confiança); as dimensões de percepção individual permanecem como limitação declarada.

VI. AMEAÇAS À VALIDADE

Validade de construto: o `alignment_score` mede alinhamento semântico à ementa e o IQAP mede qualidade pedagógica derivada do texto e dos metadados; ambos são proxies do potencial de aprendizado, e não o aprendizado efetivo dos alunos. Parte das dimensões do IQAP depende de julgamento operacionalizado por regras, e perguntas sobre percepção individual (nível de dificuldade, valor agregado) permanecem fora do alcance da medição automática. A validação cruzada com ementa de outra área mitiga parcialmente essa ameaça. **Validade interna:** 26 itens ficaram sem `prestige_score` por lacuna de cobertura do OpenAlex para conferências recentes; as fontes CORE e SJR estavam indisponíveis (endpoints bloqueados), de modo que o prestígio usa apenas métricas de fonte do OpenAlex; o casamento por título difuso pode introduzir erros residuais; a ementa está em português e os abstracts em inglês, e o modelo de embedding utilizado é orientado ao inglês. **Validade de conclusão:** o tamanho amostral por turma reduz o poder estatístico de RQ03; a correção de Benjamini-Hochberg controla a taxa de falsas descobertas, mas não cria poder onde não há. **Validade externa:** o estudo abrange uma disciplina, uma instituição e três turmas adjacentes; os resultados não são generalizáveis sem replicação, que a ferramenta ACARI torna operacionalmente trivial.

VII. CONCLUSÃO

Este estudo operacionalizou o impacto pedagógico da curadoria discente de artigos por duas medidas complementares e reproduzíveis: um proxy inferencial de alinhamento à ementa e um índice de qualidade pedagógica (IQAP). O corpus de 73 artigos está alinhado à ementa com efeito grande frente à linha de base aleatória ($\delta = +0,922$); o IQAP médio de 0,487 (14 bons, 28 regulares, 24 fracos) confirma valor pedagógico, com a qualidade metodológica como principal ponto de atenção; a composição de fontes é estável entre turmas; e o indicador bibliométrico ARQI produz ranking robusto à escolha de pesos ($\rho \geq 0,917$). A diferença entre turmas, concentrada na mais recente, sugere deriva temática a acompanhar longitudinalmente. IQAP e ARQI mostraram-se complementares: o primeiro mede qualidade pedagógico-metodológica, o segundo ranqueia qualidade e relevância bibliométrica.

Trabalhos futuros incluem: calcular o IQAP também para a linha de base; replicação longitudinal com turmas futuras; rubrica qualitativa com confiabilidade entre avaliadores para as dimensões de percepção; modelos de embedding multilíngues para eliminar a assimetria de idioma; e aplicação da ferramenta ACARI a outras disciplinas e instituições.

REFERÊNCIAS

- [1] V. R. Basili, G. Caldiera, and H. D. Rombach, “The Goal Question Metric Approach,” in *Encyclopedia of Software Engineering*. Wiley, 1994.
- [2] C. Wohlin, P. Runeson, M. Höst, M. C. Ohlsson, B. Regnell, and A. Wesslén, *Experimentation in Software Engineering*. Springer, 2012.
- [3] N. Fenton and J. Bieman, *Software Metrics: A Rigorous and Practical Approach*, 3rd ed. CRC Press, 2014.
- [4] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” in *Proc. EMNLP-IJCNLP*, 2019.

- [5] J. Priem, H. Piwowar, and R. Orr, “OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts,” *arXiv preprint arXiv:2205.01833*, 2022.